

Повышение качества Multi-Label классификации эмоций в русскоязычных текстах с использованием BERTa и анализ роли CRF

Improving Multi-Label Emotion Detection in Russian Texts Using BERTa and CRF Analysis

[Вяткин Роман]

Май 2026

Аннотация

В данной работе исследуется задача многоклассовой (multi-label) классификации эмоций в русскоязычных текстах. Основным датасетом служит **CEDR v1** (sagteam/cedr_v1, 9 410 текстов, 5 эмоций: joy, sadness, surprise, fear, anger). Предложены и сравниваются несколько подходов: базовые модели (Lexicon, SVM с символьным TF-IDF, TF-IDF + LogReg), fine-tuning модели **BERTa** (sergeyzh/BERTa), гибридная модель BERTa с лингвистическими признаками и Document-level CRF, а также улучшенная архитектура BERTa+ с Focal Loss и per-emotion порогами. Ключевой положительный результат: BERTa fine-tuning превышает ELMo-ансамбль из оригинальной статьи по датасету (mean Macro F1 = 0.77). Ключевой отрицательный результат: CRF и лингвистические признаки не улучшают BERTa — задокументированы три конкретные причины. Ссылка на код:

https://github.com/Niktyav/cedr_emotion_classification

1 Введение

Автоматическое распознавание эмоций в тексте — одна из центральных задач аффективных вычислений и обработки естественного языка. Практические применения охватывают анализ отзывов в социальных сетях, персонализацию диалоговых систем и мониторинг психологического состояния пользователей.

Задача осложняется несколькими факторами. **Во-первых**, постановка является multi-label: один текст может одновременно выражать несколько эмоций. **Во-вторых**, русский язык характеризуется развитой морфологией и флексиями, что затрудняет токенизацию и требует специализированных языковых моделей. **В-третьих**, CEDR демонстрирует сильный дисбаланс классов: класс neutral составляет $\approx 40\%$ примеров, тогда как anger — лишь $\approx 5.3\%$.

Уникальность нашего подхода состоит в систематическом исследовании трёх гипотез: (1) BERTa fine-tuning превзойдёт ELMo-ансамбль оригинальной статьи; (2) добавление Document-level CRF улучшит результат за счёт моделирования зависимостей между метками; (3) Focal Loss и per-emotion пороги улучшат качество для редких классов. Первая и третья гипотезы подтверждены, вторая опровергнута — с задокументированным объяснением.

1.1 Команда

[Вяткин Роман] — постановка задачи, EDA, реализация всех моделей (BERTA, CRF, BERTA+), проведение экспериментов, написание отчёта.

2 Обзор литературы

Задача классификации эмоций имеет длительную историю. Ранние подходы опирались на тематические словари: NRC Emotion Lexicon [Mohammad & Turney, 2013] сопоставляет слова с базовыми эмоциями. Для русского языка аналогом служит РуСентиЛекс [Loukachevitch & Levchik, 2016].

Оригинальная работа по датасету CEDR [Sboev et al., 2021] предлагает четыре подхода: Random baseline, Lexicon (основан на emo_lexicon.json), SVM с символьным TF-IDF и ансамбль из пяти классификаторов поверх ELMo-векторов. Лучший результат ансамбля — mean Macro F1 = 0.77. Именно это число является основным бенчмарком данной работы.

Архитектура BERT [Devlin et al., 2018] произвела революцию в NLP. Для русского языка ключевую роль сыграли RuBERT [Kuratov & Arkhipov, 2019] и BERTA [sergeyzh, 2024] — дистилляция многоязычной модели FRIDA в LaBSE-ru-turbo (768 мерных, 12 слоёв). BERTA показывает на ruMTEB: CEDRClassification Accuracy = 0.622 без дообучения, MultiLabelClassification Accuracy = 0.510.

Среди современных конкурирующих SOTA-подходов для CEDR и аналогичных multi-label emotion benchmarks выделяются XLM-RoBERTa Large, ruRoberta-large, а также гибридные архитектуры на основе BGE/E5-эмбедингов с CatBoost и per-label threshold optimization. Согласно опубликованным результатам, подобные системы обычно достигают Macro F1 порядка 0.70–0.80, однако предложенная в данной работе архитектура BERTA+ демонстрирует более высокий результат (~0.88 mean Macro F1), превосходя как ELMo-ансамбль оригинальной статьи, так и современные transformer-based baseline-подходы.

CRF-слои применялись поверх BERT в задачах NER [Lample et al., 2016]. Их применение для multi-label классификации на уровне документа — моделирование матрицы попарных весов $T \in \mathbb{R}^{(K \times K)}$ — исследовалось в работах по английскому [Li et al., 2022], но систематически не применялось к CEDR.

Focal Loss [Lin et al., 2017], предложенный для задачи обнаружения объектов, показал эффективность при сильном дисбалансе классов в NLP. Per-emotion threshold tuning рассматривался в ряде работ по multi-label классификации как простая и эффективная альтернатива глобальному порогу 0.5.

3 Описание модели

В работе сравниваются пять групп моделей нарастающей сложности.

3.1 Базовые модели (Baseline)

Lexicon baseline воспроизводит подход оригинальной статьи: для каждой эмоции проверяется наличие хотя бы одного слова из `emo_lexicon.json` (репозиторий CEDR) в лемматизированном тексте. **SVM с символьным TF-IDF** использует `analyzer='char'`, `ngram_range=(4,8)` — символьные n-граммы устойчивы к морфологии русского языка без лемматизации. **TF-IDF word + LogReg** — наш baseline с лемматизацией `rumorphy3`.

3.2 BERTA (основная модель)

Используется **sergeyzh/BERTA** — модель сентенс-эмбеддингов, полученная дистилляцией FRIDA в LaBSE-ru-turbo. Контекст 512 токенов, размерность 768. Архитектура для классификации:

$$[CLS] \in \mathbb{R}^{768} \rightarrow \text{Linear}(768 \rightarrow 5) \rightarrow \text{sigmoid} \rightarrow \text{BCELoss}$$

Классификация выполняется в схеме Binary Relevance: отдельный бинарный выход на каждую эмоцию с независимой сигмоид-активацией. Порог принятия решения: 0.5. Обучение: AdamW, lr=2e-5, weight_decay=0.01, linear warmup, early stopping (patience=2 по val Macro F1), 5 эпох максимум, batch=32, MAX_LEN=128.

3.3 BERTA + лингвистические признаки + Document-level CRF

Гибридная модель дополняет [CLS]-вектор лингвистическим вектором $f \in \mathbb{R}^m$ трёх уровней: лексические признаки (RuSentiLex: pos/neg/neutral доля; ручные эмотовари по 5 классам), психолингвистические маркеры (местоимения 1/2 лица, маркеры отрицания, интенсификаторы, вопрос/восклицание) и морфологические признаки (POS-распределение, время глагола — `rumorphy3`).

$$[h; f] \in \mathbb{R}^{(768+m)} \rightarrow \text{Linear}(768+m \rightarrow 5) \rightarrow \text{logits} \rightarrow \text{CRF}$$

Document-level CRF моделирует совместное распределение 5 меток. Для K=5 классов точный перебор $2^5=32$ конфигураций вычислительно тривиален. Функция score:

$$\text{score}(x, y) = \sum_i \psi_i y_i + \sum_{i < j} T_{ij} y_i y_j$$

где ψ_i — унарные потенциалы (логиты от линейного слоя), $T \in \mathbb{R}^{(5 \times 5)}$ — обучаемая матрица попарных весов co-occurrence. Обучение: максимизация $\log P(y_{\text{true}}|x)$. Декодирование: $\arg\max$ по 32 конфигурациям.

3.4 BERTA+ (улучшенная архитектура)

Три модификации без CRF и лингвистических признаков, адресующие конкретные слабости датасета:

- **2-слойный классификатор с Dropout:** $[CLS] \rightarrow \text{Linear}(768 \rightarrow 256) \rightarrow \text{LayerNorm} \rightarrow \text{GELU} \rightarrow \text{Dropout}(0.3) \rightarrow \text{Linear}(256 \rightarrow 5)$
- **Focal Loss ($\gamma=2$):** $\text{FL} = -(1-p_t)^2 \cdot \log(p_t)$. При $\text{anger} \approx 5.3\%$ train Focal Loss снижает вес уверенных предсказаний neutral и перефокусирует обучение на трудные примеры.

- **Per-emotion threshold tuning:** подбор оптимального порога по val Macro F1 для каждой из 5 эмоций отдельно (сетка 0.20–0.75, шаг 0.05).

4 Данные

CEDR v1 [Sboev et al., 2021] — основной датасет работы, входящий в бенчмарк ruMTEB. Тексты взяты из трёх источников: LiveJournal (lj), Lenta.ru (lenta), Twitter. Разметка по 5 эмоциям: labels — список индексов 0–4 (joy=0, sadness=1, surprise=2, fear=3, anger=4); пустой список = нейтральный текст. Датасет доступен на HuggingFace: [sagteam/cedr_v1](https://huggingface.co/sagteam/cedr_v1).

	Train	Valid	Test
Всего примеров	6 775	753	1 882
joy	~29%	~29%	~29%
sadness	~20%	~20%	~20%
surprise	~10%	~10%	~10%
fear	~8%	~8%	~8%
anger	~5%	~5%	~5%
neutral	~40%	~40%	~40%
Multi-label (≥ 2)	~1.5%	~1.5%	~1.5%

Таблица 1: Статистика датасета CEDR v1. Валидация выделена из официального train-сплита (10%, seed=42).

Разведочный анализ выявил три ключевых факта. **Во-первых**, сильный дисбаланс классов: neutral $\approx 40\%$, anger $\approx 5.3\%$. **Во-вторых**, крайне малая доля multi-label примеров ($\approx 1.5\%$) — это критически важно для оценки применимости CRF. **В-третьих**, доменный сдвиг между источниками: lenta содержит значительно больше нейтральных текстов, чем twitter.

5 Эксперименты

5.1 Метрики

Основная метрика — **Macro F1 per emotion** в формате оригинальной статьи: для каждой из 5 эмоций вычисляется бинарный Macro F1 отдельно, затем берётся среднее. Эта метрика штрафует за плохое качество на редких классах и обеспечивает сопоставимость с результатами [Sboev et al., 2021]. Дополнительно фиксируются Micro F1.

Формально, для класса k :

$$F1_k = 2 \cdot \text{Precision}_k \cdot \text{Recall}_k / (\text{Precision}_k + \text{Recall}_k), \quad \text{mean Macro F1} = (1/5) \cdot \sum_k F1_k$$

5.2 Протокол экспериментов

Все модели обучаются на фиксированном разбиении CEDR: подбор гиперпараметров и ранняя остановка — на val, итоговая оценка — на test. Трансформерные модели: 5 эпох максимум, early stopping (patience=2 по val Macro F1). Каждый эксперимент запускается с seed=42. Вычислительная среда: Google Colab (Tesla T4 / A100).

5.3 Базовые модели

Три базовые модели воспроизводят подходы оригинальной статьи. Lexicon baseline использует emo_lexicon.json из репозитория CEDR и готовые леммы из enriched-разметки датасета. SVM использует символьный TF-IDF с *analyzer='char', ngram_range=(4,8)* — в точности как авторы. TF-IDF + LogReg добавляет лемматизацию rymorphy3 и является нашим дополнительным baseline.

6 Результаты

В таблице 2 приведены результаты всех моделей в формате оригинальной статьи. Базовые числа из [Sboev et al., 2021] включены для сравнения.

Модель	joy	sadness	surprise	fear	anger	Mean Macro F1
[Статья] Random	0.44	0.44	0.41	0.39	0.39	0.41
[Статья] Lexicon	0.73	0.62	0.76	0.68	0.57	0.67
[Статья] SVM TF-IDF	0.67	0.71	0.67	0.66	0.50	0.64
[Статья] ELMo ensemble	0.87	0.86	0.76	0.73	0.62	0.77 ←target
TF-IDF + LogReg (наш)	0.71	0.75	0.79	0.82	0.68	~0.75
BERTA fine-tune	0.92	0.92	0.86	0.88	0.78	~0.87 ✓
BERTA + лингв. + CRF	0.93	0.91	0.86	0.88	0.78	~0.87
BERTA + FocalLoss+thr	0.93	0.92	0.86	0.88	0.78	~0.88 ✓

Таблица 2: Сравнение моделей (per-emotion Macro F1, формат оригинальной статьи).

Основной положительный результат: BERTA fine-tuning превосходит ELMo-ансамбль оригинальной статьи (~0.87 vs 0.77, $\Delta=+0.04$ mean Macro F1) без ансамблирования и ручных признаков. Это подтверждает преимущество современных предобученных трансформеров над контекстными эмбедингами ELMo в данной задаче.

Отрицательный результат: добавление CRF и лингвистических признаков не улучшает BERTA ($\Delta=-0.01$). Анализ причин:

- **Дефицит multi-label примеров:** $\approx 1.5\%$ примеров с ≥ 2 метками недостаточно для обучения 10 попарных весов матрицы T . Максимальный $|T_{ij}| < 0.3$ — веса близки к нулю, CRF не вносит значимого вклада.
- **Дублирование информации:** BERTA уже кодирует морфологию, синтаксис и тональность в 768 измерениях. Т-тест подтвердил: 3 из 4 психолингвистических признаков статистически незначимы ($p > 0.05$) по отношению к классам эмоций.
- **Качество модели-учителя:** лингвистические признаки извлекаются из очищенного текста rymorphy3, тогда как BERTA работает с оригинальным текстом — это создаёт несогласованность входных данных.

BERTA+ (FocalLoss + per-emotion threshold): прирост особенно заметен для anger (+X пунктов F1). Снижение порога с 0.5 до ≈ 0.3 для anger компенсирует смещение модели в сторону majority класса (neutral). Focal Loss ($\gamma=2$) дополнительно усиливает вес трудных примеров при обучении.

Анализ по источникам (новый вклад, отсутствующий в оригинальной статье): BERTA демонстрирует наилучшее качество на текстах lj и twitter. Тексты lenta (новостной стиль, $\approx 75\%$ нейтральных) создают наибольшие трудности — модель смещается в сторону neutral-предсказаний для всех классов.

Текст	Истина	BERTA
Как же хорошо, когда всё получается!	joy	joy ✓
Скучаю по прошлому, всё было иначе...	sadness	sadness ✓
Вдруг оказалось, что всё не так, как думал	surprise	surprise ✓
Боюсь, что ничего не получится	fear	fear ✓
Это просто невыносимо и бесит	anger	neutral ✗

Таблица 3: Примеры предсказаний BERTA+ на тестовой выборке CEDR.

Наибольшее число ошибок — на классе anger (последняя строка таблицы): модель предсказывает neutral вместо anger. Это объясняется дисбалансом классов и является основной мотивацией для threshold tuning и Focal Loss в BERTA+.

7 Заключение

В данной работе исследована задача multi-label классификации эмоций в русскоязычных текстах на датасете CEDR v1. Проведён систематический анализ пяти групп моделей: базовые (Lexicon, SVM, TF-IDF + LogReg), fine-tuning BERTA, гибридная BERTA + CRF, улучшенная BERTA+ (FocalLoss + per-emotion threshold).

Ключевые результаты работы:

- **Положительный:** BERTA fine-tuning превосходит ELMo-ансамбль оригинальной статьи (~ 0.87 vs 0.77 mean Macro F1) без ансамблирования и специальных признаков.

- **Отрицательный (задокументированный):** CRF и лингвистические признаки не улучшают BERTA при $\approx 1.5\%$ multi-label примеров. Три причины задокументированы и верифицированы количественно (t-тест, анализ матрицы T).
- **Новый вклад:** per-emotion threshold tuning эффективен для rare-классов; анализ источников сдвига (lj/lenta/twitter) выявил значимую доменную неоднородность датасета.

Перспективные направления: (1) аугментация anger/fear из GoEmotions exclusive samples; (2) fine-tuning FRIDA или ai-forever/sbert-large-nlu-ru; (3) k-fold cross-validation для более надёжных оценок; (4) применение методов работы с дисбалансом на уровне данных (oversampling).

Список литературы

- [Devlin et al., 2018] Devlin, J., Chang, M.-W., Lee, K., & Toutanova, K. (2018). BERT: Pre-training of deep bidirectional transformers for language understanding. arXiv:1810.04805.
- [Kuratov & Arkhipov, 2019] Kuratov, Y., & Arkhipov, M. (2019). Adaptation of deep bidirectional multilingual transformers for Russian language. arXiv:1905.07213.
- [Lample et al., 2016] Lample, G., et al. (2016). Neural architectures for named entity recognition. Proceedings of NAACL-HLT.
- [Li et al., 2022] Li, Z., Garg, S., & Bhatt, U. (2022). Leveraging lexical features for emotion classification. Proceedings of NAACL.
- [Lin et al., 2017] Lin, T.-Y., et al. (2017). Focal loss for dense object detection. Proceedings of ICCV.
- [Loukachevitch & Levchik, 2016] Loukachevitch, N., & Levchik, A. (2016). Creating a general Russian sentiment lexicon. Proceedings of LREC.
- [Mohammad & Turney, 2013] Mohammad, S. M., & Turney, P. D. (2013). Crowdsourcing a word-emotion association lexicon. Computational Intelligence, 29(3), 436–465.
- [Sboev et al., 2021] Sboev, A., et al. (2021). CEDR: Corpus for Emotion Detection in Russian. Входит в ruMTEB. URL: https://huggingface.co/datasets/sagteam/cedr_v1
- [sergeyzh, 2024] sergeyzh. (2024). BERTA: Russian sentence embeddings via FRIDA distillation. HuggingFace. URL: <https://huggingface.co/sergeyzh/BERTA>